

PROJETO FINAL MACHINE LEARNING — IoT

Pós-graduação em Internet of Things

Objetivo: Desenvolver um projeto detecção de falhas em equipamentos.

1. Identificação da Projeto

Nome da dupla (caso não seja dupla, nome do projeto individual):

Aluno 1:	Gabriel Victorio Ditomaso
E-mail:	ditomaso.gabriel@aluno.ifsp.edu.br
Telefone / WhatsApp:	(16) 99963-2376
Aluno 2:	André Jorge Othon Teixeira
E-mail:	andre.othon@aluno.ifsp.edu.br
Telefone / WhatsApp:	(17) 996804994

2. Título do projeto

Título: Sistema de detecção de falhas em sistemas de telemetria agrícola

3. Problema que a dupla deseja resolver

Um conjunto de equipamentos de irrigação agrícola é composto por diversos sensores e informações. Constantemente ocorre falhas em apenas um sensor ou horário inconsistente, gps, equipamentos desligados ou com problemas no radio (Lora), problemas em sensores de pressão e assim por diante, basicamente a identificação desses defeitos é feita de forma manual já que os padrões de dados são conhecidos. Foi proposto desenvolver um algoritmo para classificar se o sistema está funcionando corretamente ou não.

4. Metodologia

A metodologia do projeto foi dividida em cinco etapas principais:

- Coleta e estruturação dos IDs reais dos equipamentos;
- Geração de dataset sintético;
- Normalização dos dados;
- Treinamento dos modelos de Machine Learning;
- Desenvolvimento de uma aplicação de diagnóstico em Streamlit.

4.1 Estruturação dos Equipamentos

Inicialmente, foi utilizada uma planilha real contendo os IDs dos equipamentos operacionais da empresa.

A planilha possui informações como:

- identificação dos equipamentos;
- canais de comunicação;
- módulos;
- usinas;

- tipos de equipamentos.

O sistema realiza automaticamente a leitura da planilha e classifica os dispositivos em categorias como:

- bomba;
- carretel;
- aspersor;
- identificador do projeto
- repetidora;
- hidrômetro.

Essa classificação é feita através da análise textual dos nomes dos equipamentos.

4.2 Falhas Simuladas

As principais falhas simuladas foram:

Falhas de bomba:

- BOMBA_OFFLINE
- GPS_BOMBA_PROBLEMA
- PRESSAO_BOMBA_NULA

Falhas de carretel:

- CARRETEL_OFFLINE
- ASPERSOR_OFFLINE
- GPS_ASPERSOR_PROBLEMA
- GPS_CARRETEL_PROBLEMA
- PRESSAO_ASPERSOR_SUSPEITA
- RECOLHIMENTO_ZERADO_COM_BOMBA_OPERANDO

As falhas são inseridas aleatoriamente durante a geração do dataset.

4.3 Normalização dos Dados

Os dados gerados foram organizados em uma estrutura tabular normalizada.

Cada linha representa um equipamento individual em um determinado instante de tempo.

Foram criadas colunas auxiliares importantes para Machine Learning, como:

- gps_valido;
- bomba_operando;
- null_count;
- pressao_num;
- rpm_num;
- velocidade_recolhimento_num.

Essas features facilitam o aprendizado dos modelos.

4.4 Regras de Diagnóstico

Antes do treinamento, o sistema aplica regras de negócio para corrigir e validar os diagnósticos.

Exemplos:

- bomba com RPM zero, pressão nula e GPS inválido → BOMBA_OFFLINE;
- carretel sem GPS e sem pressão e aspersor sem gps e pressão → CARRETEL_OFFLINE;
- pressão positiva com recolhimento zerado → RECOLHIMENTO_ZERADO.

Como uma mesma linha pode apresentar múltiplos problemas, o sistema utiliza uma lista de prioridade para selecionar um único label principal.

4.5 Features Utilizadas

As principais features utilizadas pelos modelos foram:

- project_numeric_id
- equipamento_id
- bomba_operando
- gps_valido
- gps_aspersor_valido
- gps_carretel_valido
- pressao_num
- rpm_num
- pressao_aspersor_num
- pressao_carretel_num
- velocidade_recolhimento_num
- metragem_mangueira_num
- null_count

Essas variáveis representam o estado operacional dos equipamentos.

5. Modelos Utilizados

5. Processo de Treinamento

O treinamento foi realizado utilizando:

- 75% dos dados para treino;
- 25% para teste.

Foi utilizado o método train_test_split com stratify, garantindo equilíbrio entre as classes.

As labels foram convertidas para valores numéricos utilizando LabelEncoder.

Após o treinamento, os modelos foram exportados em formato .pkl.

5.1 Árvore de Decisão (Decision Tree)

O modelo de Árvore de Decisão funciona criando regras hierárquicas baseadas nas features do dataset.

O algoritmo aprende divisões lógicas, por exemplo:

- *se RPM = 0 e GPS inválido → possível bomba offline;*
- *se pressão do carretel > 0 e recolhimento = 0 → possível falha mecânica.*

Vantagens

- *fácil interpretação;*
- *baixo custo computacional;*
- *boa visualização das decisões.*

Desvantagens

- *sensível a overfitting;*
- *menor robustez em datasets muito variados.*

5.2 Random Forest

O Random Forest utiliza múltiplas árvores de decisão simultaneamente.

Cada árvore faz sua própria previsão, e o modelo final utiliza votação entre elas.

Esse método reduz overfitting e melhora a robustez do sistema.

Vantagens

- *maior precisão;*
- *melhor generalização;*

- *maior resistência a ruídos.*

Desvantagens

- *maior custo computacional;*
- *menor interpretabilidade.*

6. Resultados e análise

Os resultados mostraram que ambos os modelos foram capazes de identificar padrões de falha.

O modelo de Árvore de Decisão apresentou desempenho superior em relação ao Random Forest, principalmente em cenários com múltiplas variáveis correlacionadas.

As principais vantagens observadas foram:

- detecção automática de falhas;
- redução da necessidade de análise manual;
- identificação rápida de problemas operacionais;
- possibilidade de manutenção preditiva;
- escalabilidade para grandes quantidades de equipamentos.

Outro ponto importante foi a capacidade do sistema de trabalhar diretamente com pacotes JSON semelhantes aos utilizados em aplicações IoT reais.

A aplicação desenvolvida em Streamlit permitiu:

- inserção manual de pacotes JSON;
- análise em tempo real;
- comparação entre modelos;
- visualização dos diagnósticos;
- exportação dos resultados.

7. Conclusão

O projeto demonstrou que técnicas de Machine Learning podem ser aplicadas com sucesso no diagnóstico de falhas em equipamentos IoT agrícolas.

A utilização de datasets sintéticos permitiu criar uma base para teste sem grandes volumes de dados reais rotulados.

Os modelos desenvolvidos conseguiram identificar padrões relevantes de falhas operacionais em motobombas e carretéis irrigadores.

Além disso, o sistema terá continuidade com dados reais para treinamento posteriormente para treinamento e comparar se o dataset sintético impactará muito e também será de grande uso.

Link para o GitHub: https://github.com/Gabuzin/ML_DIAGNOSTICO_EQUIPAMENTOS